

人工智能综合基础

- 概率统计

高 尉

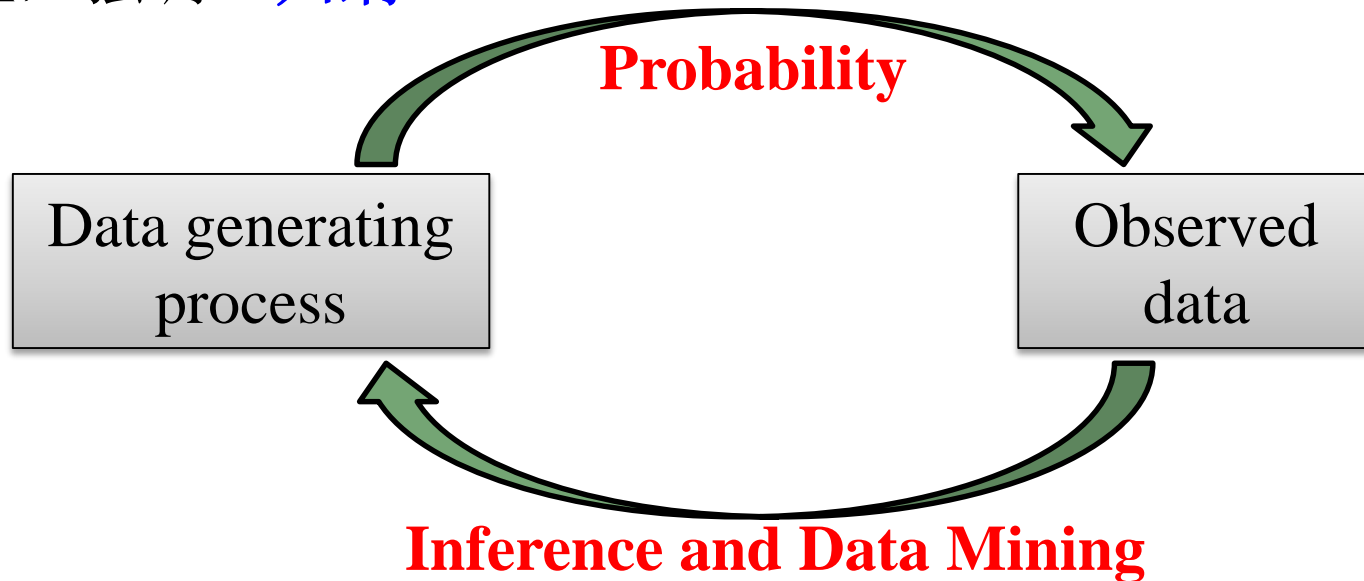


问题

简答： 概率与统计，最主要的区别


概率与统计

- **概率**：研究事件的不确定性，在给定数据生成过程中观察、研究数据的性质，强调**公理体系**、**推理**
- **统计**：收集与分析数据，根据观察的数据反思其数据生成过程，强调“**归纳**”



概率与统计重要的区别在于公理体系化

知识结构



必然现象与随机现象

必然现象：在一定条件下必然发生的现象，其特征是条件完全决定结果

随机现象：在一定条件下可能出现、可能不出现的现象，其特征是条件不能完全决定结果

随机现象的二重属性：

- **偶然性：**对随机现象做一次观察，观察结果不可预知
- **必然性：**对随机现象做大量观察，观察结果具有一定的规律性，即统计规律性

随机试验(用E表示) 具备以下三个特点的试验：

- **可重复：**可在相同的条件下重复进行
- **多结果：**结果不止一个，所有可能的结果事先已知
- **不确定：**试验前无法预测/确定哪一种结果

随机试验

- 样本点：试验的每一种可能的结果，记为 ω
- 样本空间：试验中所有可能的结果组成的集合，记为 Ω

随机事件：样本空间 Ω 的子集，由单个或某些样本点 ω 的集合，本质是集合，一般用字母 A 、 B 、 C 等。称“**随机事件 A 发生**”当且仅当试验的结果是子集 A 中的元素

- 必然事件：试验中必定发生的事件，记为 Ω
- 不可能事件：试验中不可能发生的事件，用 \emptyset 表示

记号	概率论	集合论
Ω	样本空间, 必然事件	全集
\emptyset	不可能事件	空集
ω	基本事件	元素
A	随机事件	子集

事件间的关系

$A \subset B$: 若 A 发生必然导致 B 发生, 称事件 B 包含事件 A

$A = B$: 若 $A \supset B$ 且 $B \supset A$

$A \cup B$: 事件 A 和 B 至少发生一个的事件

$A \cap B = AB$: 事件 A 和 B 同时发生的事件

\bar{A} : 事件 A 不发生的事件

互斥/互不相容: 若事件 A 和 B 不可能同时发生

$A - B$: A 发生, 而 B 不发生的事件

$$A - B = A - AB = A\bar{B} = (A \cup B) - B$$

事件与集合的对应关系

记号	概率论	集合论
\bar{A}	A 的对立事件	A 的补集
$A \subset B$	A 发生必然导致 B 发生	A 是 B 的子集
$A = B$	事件 A 与事件 B 相等	集合 A 与集合 B 相等
$A \cup B$	事件 A 与事件 B 的和	集合 A 与集合 B 的并集
$A \cap B$	事件 A 与 B 的积事件	集合 A 与集合 B 的交集
$A - B$	事件 A 与事件 B 的差	集合 A 与集合 B 的差集
$A \cap B = \emptyset$	事件 A 与事件 B 互不相容	集合 A 与集合 B 中没有相同的元素

事件的运算规律

- 幂等律: $A \cup A = A, A \cap A = A$
- 交换律: $A \cup B = B \cup A, A \cap B = B \cap A$
- 结合律: $(A \cup B) \cup C = A \cup (B \cup C)$
 $(A \cap B) \cap C = A \cap (B \cap C)$
- 分配律: $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
 $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$
- 对偶律: $\overline{A \cup B} = \bar{A} \bar{B}, \overline{A \cap B} = \bar{A} \cup \bar{B}$

上述规律可推广到多个事件

例题

设A、B、C为任意三个随机事件，证明

$$(\bar{A} \cup B)(A \cup \bar{B})(\bar{A} \cup \bar{B})(A \cup B) = \emptyset$$

$$(A - B) \cup (B - C) = (A \cup B) - BC$$

设A与B同时发生，则C必发生，则（ ）

- A) $P(C) \leq P(A) + P(B) - 1$ B) $P(C) \geq P(A) + P(B) - 1$
C) $P(C) = P(AB)$ D) $P(C) = P(A \cup B)$

问题

简答：频率与概率的关系

概率

- 概率用于度量事件发生的可能性，是事件的固有属性
- 频率在一定程度上反映了事件发生的可能性
- 概率是恒定的，而频率在试验中具有随机性
- 若试验次数足够多，频率与概率非常接近
- 概率可以通过频率来“测量”，频率是概率的一个近似

概率的公理化定义 在随机试验的样本空间 Ω 上，对于每一个事件 A 赋予一个实数，记为 $P(A)$ ，若满足下列条件，称 $P(A)$ 为事件 A 发生的概率：

- 非负性： $P(A) \geq 0$
- 规范性： $P(\Omega) = 1$
- 可列可加性： 若 A_1, A_2, \dots 可列个两两互不相容的事件，则

$$P(\cup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$$

概率的性质

- ◆ 对不可能事件 \emptyset 有 $\mathbf{P(\emptyset) = 0}$, 对必然事件 Ω 有 $\mathbf{P(\Omega) = 1}$ 【事件可以推导出概率、但反之不成立】

- ◆ **有限可加性** 若 $A_1, A_2 \cdots A_n$ 是两两不相容事件, 则

$$P(A_1 \cup A_2 \cup \cdots \cup A_n) = P(A_1) + P(A_2) + \cdots P(A_n)$$

- ◆ 对任意事件 A 有 $\mathbf{P(\bar{A}) = 1 - P(A)}$

- ◆ 若 $B \subset A$, 则 $P(A - B) = P(A) - P(B)$ 和 $P(B) \leq P(A)$

- ◆ 对任意事件 A 和 B

$$P(A - B) = P(A) - P(AB) = P(A \cup B) - P(B)$$

- ◆ 容斥原理:

$$P(A \cup B) = P(A) + P(B) - P(AB)$$

$$P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC)$$

例题

设A与B满足 $P(A)=P(B)=1/2$, $P(A \cup B)=1$ 则()

- A) $A \cup B = \Omega$ B) $AB = \emptyset$
C) $P(\bar{A} \cup \bar{B}) = 1$ D) $P(A - B) = 0$

设A和B满足 $P(AB) = P(\bar{A}\bar{B})$, 且 $P(A) = p$, 求 $P(B)$

设 $P(A) = P(B) = P(C) = 1/4$, $P(AB) = 0$, $P(AC) = P(BC) = 1/8$, 求A, B, C全不发生的概率

古典概型

古典概型：试验结果只有有限种可能 $\Omega = \{\omega_1, \omega_2, \dots, \omega_n\}$ ，每种结果发生的可能性相同 $P(\omega_i) = P(\omega_j)$

若事件 A 包含 k 个基本事件，则事件 A 发生的概率为：

$$P(A) = k/n = |A|/|\Omega|$$

计数的两条基本原理：加法原理、乘法原理

排列、组合（组合计数十二路了解）

以前的经典例题：抽签、生日悖论、Matching问题

例题

一个盒子中装有 n 个球，编号为 $1, 2, \dots, n$ ，有放回的取出 k 个球，求取出的球中最大编号为 m 的概率。

几何概型

在一个测度有限的区域 Ω 内等可能性投点, 落入 Ω 内的任意子区域 A 的可能性与 A 的测度成正比, 与 A 的位置与形状无关, 这样的概率模型称之为**几何概型**. 事件 A 发生的概率为

$$P(A) = \frac{A \text{ 的测度}}{\Omega \text{ 的测度}} = \frac{\mu(A)}{\mu(\Omega)}$$

例: 假设一乘客到达汽车站的时间是任意的, 客车间隔一段时间发班, 请规划最长的间隔发车时间, 才能确保乘客候车等待时间不超过20分钟的概率大于80%.

条件概率

条件概率：设 A 和 B 为同一样本空间下的随机事件, 且 $P(A) > 0$,

$$P(B|A) = P(AB)/P(A)$$

为事件 A 发生的条件下事件 B 发生的概率, 简称 **条件概率**

两种计算方法：1) 定义 2) 空间缩减法

条件概率是概率，具有概率的所有性质：

- 非负性、规范性、可列可加性、容斥原理
- $P(B_1 - B_2|A) = P(B_1|A) - P(B_1B_2|A)$
- 乘法公式： $P(AB) = P(A)P(B|A) = P(B)P(A|B)$

问题

简答：全概率公式、贝叶斯公式

全概率公式和贝叶斯公式

若事件 A_1, A_2, \dots, A_n 为样本空间 Ω 的一个划分, 对任意事件 B 有

$$P(B) = \sum_{i=1}^n P(BA_i) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

称之为 **全概率公式**

贝叶斯公式: 设 A_1, A_2, \dots, A_n 为样本空间 Ω 的一个划分, 且事件 B 满足 $P(B) > 0$. 对任意 $1 \leq i \leq n$ 有

$$P(A_i|B) = \frac{P(A_iB)}{P(B)} = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

小概率原理: 若事件 A 在一次试验中发生的概率非常小, 但经过多次独立地重复试验, 事件 A 的发生是必然的

例题

事件 A 、 B 、 C 中 A 与 C 互不相容, $P(AB) = 1/2$, $P(C) = 1/3$,
求 $P(AB|\bar{C})$

例题

第一个袋子中有5个红球和3个白球，第二个袋子中有4个红球和3个白球，从第一个袋子中取3个球放入第二个袋子后，从第二个袋子任取一球，求：1) 此球为红球的概率

2) 若已知第二个袋子取出红球，求从第一个袋子取出3个球无红球的概率

例题

犯人a, b, c均被判为死刑, 法官随机赦免其中一人, 看守知道谁被赦免但不会说. 犯人a问看守: b和c谁会被执行死刑? 看守的策略: i) 若赦免b, 则说c; ii) 若赦免c, 则说b; iii) 若赦免a, 则以1/2的概率说b或c. 看守回答a: 犯人b会被执行死刑, 求在此信息下三人被赦免的概率?

两事件的独立性

事件 A 和 B 独立 $\Leftrightarrow P(AB) = P(A)P(B) \Leftrightarrow P(B|A) = P(B)$

A 和 B 独立 $\Leftrightarrow A$ 和 \bar{B} 独立 $\Leftrightarrow \bar{A}$ 和 B 独立 $\Leftrightarrow \bar{A}$ 和 \bar{B} 独立

概率为0或1的事件与任何事件独立

概念: 若事件 A, B, C 的相互独立与 A, B, C 的两两独立

性质: 若事件 $P(B) \in (0,1)$, 则

$$A \text{ 和 } B \text{ 独立} \Leftrightarrow P(A|B) = P(A|\bar{B}) \Leftrightarrow P(A|B) + P(\bar{A}|\bar{B}) = 1$$

问题


简答：独立性与互不相容性的关系

独立与互斥的关系


A 与 B 相互独立: $P(AB) = P(A)P(B)$, 独立性与概率相关,
反映事件的概率属性

A 与 B 互不相容: $AB = \emptyset$, 与事件运算关系相关, 与概率无关

独立与互斥反映事件不同的性质, 无必然联系



A 与 B 独立, 但并不互斥



A 与 B 互斥, 但并不独立

例题

事件 A 、 B 、 C 两两独立, 且 C 与 $A - B$ 独立, 则 A 、 B 、 C 相互独立.

案例分析：验证大矩阵乘法是否相等

给定矩阵 $A, B, C \in \{0,1\}^{n \times n}$ ($n \geq 10000000$), 验证 $AB = C$?

独立随机产生一个向量 $r \in \{0,1\}^n$, 判断

$$A(Br) = Cr?$$

计算 $A(Br)$ 和 Cr 的复杂度均为 $O(n^2)$. 若 $A(Br) \neq Cr$ 则直接有 $AB \neq C$; 若 $A(Br) = Cr$ 并不能得出 $AB = C$.

将上述过程独立进行 K 次, 可以证明以较大的概率有 $AB = C$ 成立, 该过程被称为Freivalds算法

Freivalds算法分析

该算法的计算复杂度为 $O(Kn^2)$, 若 K 比较小则显著降低了计算复杂度.

若返回No, 则必然有 $AB \neq C$

若返回Yes, 然而并不一定有 $AB = C$ 成立, 下面研究成立的概率.

设 $D = AB - C \neq 0$, 则D中必存在一些元素不为0, 不妨令 $d_{11} \neq 0$.
对任意一轮循环, 不妨设随机向量 $r = \{r_1, r_2, \dots, r_n\}$, 根据返回Yes可知 $Dr = 0$, 进一步可得向量 Dr 的第一个元素等于0, 即

$$\sum_{j=1}^n d_{1j}r_j = 0 \implies r_1 = -\frac{1}{d_{11}} \sum_{j=2}^n d_{1j}r_j$$

Freivalds算法分析

$$\sum_{j=1}^n d_{1j}r_j = 0 \implies r_1 = -\frac{1}{d_{11}} \sum_{j=2}^n d_{1j}r_j$$

无论 r_2, \dots, r_n 取何值, 等式 $\sum_{j=1}^n d_{1j}r_j = 0$ 是否成立由 r_1 的值决定.
根据 $P(r_1 = 0) = P(r_1 = 1) = 1/2$ 可知 $\sum_{j=1}^n d_{1j}r_j = 0$ 成立的概率不超过 $1/2$

在 K 轮独立循环中, 等式 $\sum_{j=1}^n d_{1j}r_j = 0$ 成立的概率不超过 $\frac{1}{2^K}$

取 $K = \log_2 n$, 则算法Freivalds计算复杂度为 $O(n^2 \log n)$, 若算法返回No, 则 $AB \neq C$; 若返回Yes, 则有

$$P(AB = C) > 1 - 1/n$$

即至少以 $1 - 1/n$ 的概率有 $AB = C$ 成立

第二章 随机变量及其分布

高 尉



2023-人工智能综合...

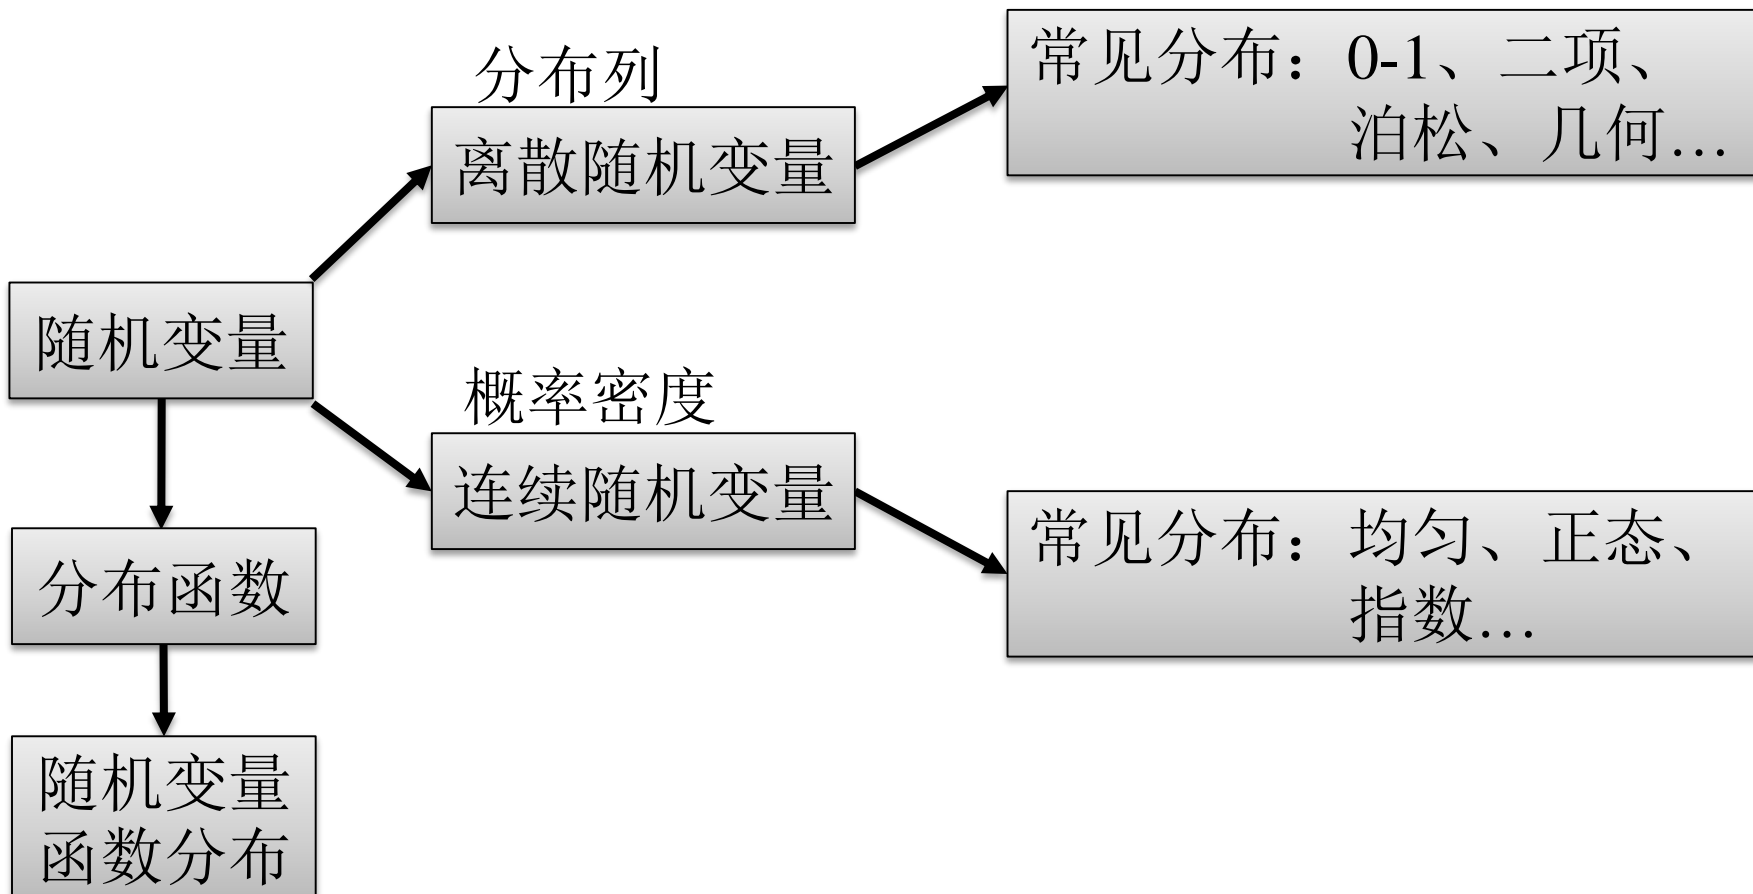
群号: 188231748



扫一扫二维码，加入群聊。




知识结构



随机变量

将样本空间 Ω 中每个样本点 ω 与一实数 $X(\omega)$ 相对应, $X(\omega)$ 是 ω 的实值函数, 称实值函数 $X(\omega): \Omega \rightarrow \mathbb{R}$ 为随机变量, 简记 X



给定任意随机变量 X 和实数 x , 函数

$$F(x) = P(X \leq x)$$

称为随机变量 X 的**分布函数**, 分布函数的本质是概率

- 单调性: 若 $x_1 < x_2$, 则 $F(x_1) \leq F(x_2)$
 - 规范性: $F(x) \in [0,1]$ 且 $F(-\infty) = 0, F(+\infty) = 1$
 - 右连续性: $F(x+0) = F(x)$
- 分布函数可由这三条性质完全刻画
- 对任意实数 $x_1 < x_2$, $P(x_1 < X \leq x_2) = F(x_2) - F(x_1)$

$$P(X = x_2) = F(x_2) - F(x_2 - 0)$$

例题

性质：若 $F_1(x), F_2(x)$ 是分布函数，则 $aF_1(x) + (1 - a)F_2(x)$ 也是分布函数，其中 $a \in (0,1)$

例：设随机变量 X 的分布函数为

$$F(x) = \begin{cases} 0 & x \leq a \\ x^2 - b & a < x \leq \sqrt{2} \\ c & x > \sqrt{2} \end{cases}$$

求 $P(X = a)$ 和 $P[1 < X < 3]$

离散型随机变量

离散型随机变量：随机变量的取值是有限的、或无限可列的。

假设其取值为 $x_1, x_2, \dots, x_n, \dots$, 事件 $X = x_k$ 的概率记为

$$p_k = P(X = x_k) \quad k = 1, 2, \dots$$

称之为**随机变量X的分布列**，分布列包含随机变量的取值和概率，完全刻画其概率属性

X	x_1	x_2	\dots	x_n	\dots
P	p_1	p_2	\dots	p_n	\dots

性质：随机变量 X 的分布列 $P(X = x_k) = p_k$ ($k \geq 1$) 满足 $p_k \geq 0$ 且 $\sum_k p_k = 1$

例:若随机变量 X 的分布列 $P(X = k) = c/4^k$ ($k \geq 0$), 求 $P(X = 1)$

均匀/0-1分布

设随机变量 X 的取值为 x_1, x_2, \dots, x_n , 且 $P(X = x_i) = 1/n$, 称 X 服从离散 **均匀分布**

期望: $E(X) = \sum_{i=1}^n \frac{x_i}{n}$ 方差: $E(X) = \sum_{i=1}^n \frac{x_i^2}{n} - \left(\sum_{i=1}^n \frac{x_i}{n} \right)^2$

德国坦克数量问题: 假设德国生产 N 辆坦克, 编号为 $1, 2, \dots, N$, 盟军战斗中随机击毁 k 辆, 被随机击毁坦克编号分别为 x_1, x_2, \dots, x_k , 如何估计 N 的大小

随机变量 X 的取值为 $\{0, 1\}$, 其分布列 $P(X = 1) = p$, 称 X 服从参数为 p 的**0-1分布**, 或 **Bernoulli 分布**, 记 **$X \sim \text{Ber}(p)$**

若 $X \sim \text{Ber}(p)$, 则 $E(X) = p$ 和 $\text{Var}(X) = p(1 - p)$

二项/几何分布

用随机变量 X 表示 n 重Bernoulli试验中事件 A 发生的次数, 则 X 的取值为 $0, 1, \dots, n$, 其分布列为

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \quad k \in \{0, 1, 2, \dots, n\}$$

称随机变量 X 服从参数为 n 和 p 的**二项分布 (binomial distribution)**, 记 $X \sim B(n, p)$

对随机变量 $X \sim B(n, p)$ 有 $E(X) = np$ 和 $\text{Var}(X) = np(1 - p)$

用随机变量 X 表示事件 A 首次发生时的试验次数, 则 X 的取值为 $1, 2, \dots$, 其分布列为 $P(X = k) = (1 - p)^{k-1} p \quad (k \geq 1)$

称 X 服从参数为 p 的**几何分布**, 记为 $X \sim G(p)$

【无记忆性】 $P(X > m + n \mid X > m) = P(X > n)$

若随机变量 $X \sim G(p)$, 则有 $E(X) = 1/p$ 和 $\text{Var}(X) = (1 - p)/p^2$

负二项分布 (Pascal分布)

用 X 表示事件 A 第 r 次成功时发生的试验次数, 则 X 取值 $r, r + 1, r + 2, \dots$, 其分布列为

$$P(X = n) = \binom{n-1}{r-1} p^{r-1} (1-p)^{n-r} \cdot p \quad (n \geq r)$$

称 X 服从参数为 r 和 p 的负二项分布, 又称 **Pascal分布**

设随机变量 X 服从参数为 $p \in (0,1)$ 和 $r > 0$ 的负二项分布, 则有 $E(X) = r/p$ 和 $\text{Var}(X) = r(1-p)/p^2$

泊松定理

若随机变量 X 的分布列为 $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$ ($k \geq 0$) 其中 $\lambda > 0$ 是常数, 称随机变量 X 服从参数为 λ 的泊松分布, 记为 $X \sim P(\lambda)$

若 $X \sim P(\lambda)$, 则 $E(X) = \lambda$ 和 $\text{Var}(X) = \lambda$

泊松定理: 对任意常数 $\lambda > 0$, n 为任意正整数, 设 $np_n = \lambda$, 则对任意给定的非负整数 k , 有 $\lim_{n \rightarrow +\infty} \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{\lambda^k}{k!} e^{-\lambda}$

泊松分布的应用: 若随机变量 $X \sim B(n, p)$, 当 n 比较大而 p 比较小时, 令 $\lambda = np$, 有 $P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$
即利用泊松分布近似计算二项分布

常见分布

- 0/1分布: $X \sim \text{Ber}(p)$, $E(X) = p$ $\text{Var}(X) = p(1 - p)$
- 二项分布: $X \sim B(n, p)$, $E(X) = np$ $\text{Var}(X) = np(1 - p)$
- 几何分布: $X \sim G(p)$, $E(X) = \frac{1}{p}$ $\text{Var}(X) = \frac{1-p}{p^2}$
 - 无记忆性: $P(X > m + n \mid X > m) = P(X > n)$
- 负二项分布: X 服从参数为 r 和 p 的负二项分布
$$E(X) = \frac{r}{p} \quad \text{和} \quad \text{Var}(X) = \frac{r(1-p)}{p^2}$$
- 泊松分布: $X \sim P(\lambda)$, $E(X) = \lambda$ $\text{Var}(X) = \lambda$
 - 泊松定理: $\binom{n}{k} p^k (1 - p)^{n-k} \approx \frac{\lambda^k}{k!} e^{-\lambda}$


例题

设随机变量 $X \sim U(2,5)$, 若对 X 进行三次独立观测, 求至少两次观察值大于3的概率。

概率密度函数

设随机变量 X 的分布函数为 $F(x)$, 如果存在可积函数 $f(x)$, 使得对任意实数 x 有 $F(x) = \int_{-\infty}^x f(t)dt$ 成立, 则称 X 为连续型随机变量, 函数 $f(x)$ 为随机变量 X 的**概率密度函数**, 简称**概率密度**

概率密度函数 $f(x)$ 满足

- 非负性: $f(x) \geq 0$
 - 规范性: $\int_{-\infty}^{+\infty} f(t)dt = 1$
- }  概率密度
- 任意 $x_1 < x_2$, 有 $P(x_1 \leq X \leq x_2) = \int_{-\infty}^x f(t)dt$, $P(X = x_2) = 0$
 - $F(x)$ 在 $(-\infty, +\infty)$ 连续
 - 若 $f(x)$ 在 x_0 连续, 则 $F(x)$ 在 x_0 可导, 且有 $f(x_0) = F'(x_0)$
 - 若 $f(x)$ 为偶函数, 则有 $F(x) + F(-x) = 1$

例题

1) 若 X 的概率密度函数为 $f(x)$ ，则以下为概率密度函数的有()

A) $f(2x)$ B) $f^2(x)$ C) $2xf(x^2)$ D) $3x^2f(x^3)$

2) 若 X 与 $-X$ 具有相同的概率密度函数，则 $F(x) + F(-x) = 1$

3) 若 X 的概率密度函数为偶函数，则 $F(-x) = \frac{1}{2} - \int_0^x f(t)dt$

均匀分布和指数分布

若随机变量 X 的概率密度为 $f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \\ 0 & \text{其它} \end{cases}$, 称 X 服从
区间 $[a, b]$ 上的均匀分布, 记 $X \sim U(a, b)$

若 $X \sim U(a, b)$, 则 $E(X) = (a + b)/2$, $\text{Var}(X) = (b - a)^2/12$

给定常数 $\lambda > 0$, 若随机变量 X 的密度函数 $f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & \text{其它} \end{cases}$

称 X 服从参数为 λ 的指数分布, 记 $X \sim e(\lambda)$

若随机变量 $X \sim e(\lambda)$, 则 $E(X) = 1/\lambda$ 和 $\text{Var}(X) = 1/\lambda^2$

唯一具有无记忆性的连续随机变量: 若随机变量 $X \sim e(\lambda)$, 则对任意 $s > 0, t > 0$, 有 $P(X > s + t | X > t) = P(X > s)$

例题

- 1) 设随机变量 $\xi \sim U(-3,6)$, 试求方程 $4x^2 + 4\xi x + \xi + 2 = 0$ 有实根的概率
- 2) 已知随机变量 $Y \sim e(1)$, 对任意 $a > 0$ 求 $P[Y \leq a + 1 | Y > a]$
- 3) 随机变量 $X \sim e(\lambda)$, 且 X 落入 $(1,3)$ 内的概率达到最大, 求 λ

正态分布

给定 $u \in (-\infty, +\infty)$ 和 $\sigma > 0$, 随机变量 X 的概率密度为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad x \in (-\infty, +\infty)$$

称 X 服从参数为 μ, σ^2 的正态分布, $N(0,1)$ 为标准正态分布

性质:

- 若 $X \sim N(\mu, \sigma^2)$, 则 $E(X) = \mu$ 和 $\text{Var}(X) = \sigma^2$
- 若 $X \sim N(\mu, \sigma^2)$, 则 $\frac{X-\mu}{\sigma} \sim N(0,1)$
- 若 $X \sim N(0,1)$, 则 $\sigma X + \mu \sim N(\mu, \sigma^2)$
- 标准正态分布 $N(0,1)$ 的分布函数 $\Phi(x) = P(X \leq x)$, 偶函数
- 标准正态分布的 α 分位数 u_α 满足 $P(X > u_\alpha) = \alpha$, $u_{1-\alpha} = -u_\alpha$

例题

1) X 服从正态分布 $N(0,1)$, 给定 $\alpha \in (0,1)$, 数 u_α 满足 $P(X > u_\alpha) = \alpha$, 若 $P(|X| \leq x) = \alpha$, 则 x 等于 ()

A) $u_{\alpha/2}$ B) $u_{1-\alpha/2}$ C) $u_{(1-\alpha)/2}$ D) $u_{1-\alpha}$

2) 设 $f_1(x)$ 是 $N(0,1)$ 的概率密度函数, $f_2(x)$ 是 $[-1,3]$ 均匀分布的概率密度函数, 若

$$f(x) = \begin{cases} af_1(x) & x \leq 0 \\ bf_2(x) & x > 0 \end{cases}$$

为概率密度函数, 则 a, b 应满足什么条件

随机变量函数的概率分布

离散随机变量： X 的分布列为 $P(X = x_i) = p_i$ ， 则 $Y = g(X)$ 的分布列 $P(Y = g(x_i)) = p_i$ (若值相同则需要合并)

X 的分布列为 $P(X = n) = 1/2^n (n = 1, 2 \dots)$ ， 求 $Y = \sin(X\pi/2)$ 的分布函数

随机变量函数的概率分布

已知连续随机变量 X 的概率密度为 $f_X(x)$ ，求新随机变量 $Y = g(X)$ 的概率密度 $f_Y(y)$ ？

求解步骤：1) 求解 $Y=g(X)$ 的分布函数

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y) = \int_{g(x) \leq y} f_X(x) dx$$

2) 利用分布函数和概率密度关系求解密度函数 $f_Y(y) = F'_Y(y)$

数学工具 — 积分求导公式

$$F(y) = \int_{\psi(y)}^{\varphi(y)} f(x) dx$$
$$F'(y) = f(\varphi(y))\varphi'(y) - f(\psi(y))\psi'(y)$$

例题

已知 X 的分布函数 $F_X(x)$ ，求 $Y = 2X + 1$ 的分布函数

已知 X 服从均匀分布 $U(-\pi/2, \pi/2)$ ，求 $Y = \sin(x)$ 的概率密度

练习题：


1) 若 $X \sim N(0,1)$ ，求 $Y = e^X, Y = |X|, Y = X^2 + 1$ 的概率密度

2) 若 $X \sim e(1)$ ，求 $Y = e^X$ 的概率密度

第三章 多维随机变量



知识结构



二维随机变量

设 $X = X(\omega)$ 和 $Y = Y(\omega)$ 为定义在样本空间 Ω 上的随机变量, 由它们构成的向量 (X, Y) 称为**二维随机向量**

设 (X, Y) 为二维随机变量, 对任意实数 $x \in (-\infty, +\infty)$ 和 $y \in (-\infty, +\infty)$, 称 $F(x, y) = P(X \leq x, Y \leq y)$ 为**二维随机变量 (X, Y) 的分布函数**, 或称为**随机变量 X 和 Y 的联合分布函数**

□ 分布函数 $F(x, y)$ 对每个变量单调不减

- 固定 y , 当 $x_1 > x_2$ 时有 $F(x_1, y) \geq F(x_2, y)$
- 固定 x , 当 $y_1 > y_2$ 时有 $F(x, y_1) \geq F(x, y_2)$

□ 对任意 $x \in (-\infty, +\infty)$ 和 $y \in (-\infty, +\infty)$, 分布函数 $F(x, y) \in [0, 1]$, 且 $F(+\infty, +\infty) = 1$ 和

$$F(-\infty, y) = F(x, -\infty) = F(-\infty, -\infty) = 0$$

□ 分布函数 $F(x, y)$ 关于每个变量右连续

边缘分布与独立性

设二维随机变量 (X, Y) 的联合分布函数为 $F(x, y)$, 称

$$F_X(x) = P(X \leq x) = P(X \leq x, y < +\infty) = \lim_{y \rightarrow +\infty} F(x, y)$$

为随机变量 X 的边缘分布函数.

同理定义随机变量 Y 的边缘分布函数为:

$$F_Y(y) = P(Y \leq y) = P(Y \leq y, x < +\infty) = \lim_{x \rightarrow +\infty} F(x, y)$$

$X \leq x$ 和 $Y \leq y$ 相互独立, $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$,
等价于 $F(x, y) = F_X(x) F_Y(y)$, 则称随机变量 **X 与 Y 相互独立**

随机事件的独立性: $P(AB) = P(A)P(B)$

随机变量的独立性

例题：设二维随机变量 (X, Y) 的联合分布函数为

$$F(x, y) = \begin{cases} A(B + \arctan x)(C - e^{-y}) & x \in R, y > 0 \\ 0 & \text{其它} \end{cases}$$

求 $F(0, 1)$

二维离散型随机变量

若二维随机变量 (X, Y) 的取值是有限个或无限可列的, 称 (X, Y) 为二维离散型随机变量

设离散型随机变量 (X, Y) 的取值分别为 (x_i, y_j) , $i, j = 1, 2, \dots$, 则称

$$p_{ij} = P(X = x_i, Y = y_j)$$

为 (X, Y) 的联合分布列

性质: $p_{ij} \geq 0$ 和 $\sum_{i,j} p_{ij} = 1$

$X \backslash Y$	Y				
	y_1	y_2	\cdots	y_j	\cdots
x_1	p_{11}	p_{12}	\cdots	p_{1j}	\cdots
x_2	p_{21}	p_{22}	\cdots	p_{2j}	\cdots
\vdots	\vdots	\vdots		\vdots	
x_i	p_{i1}	p_{i2}	\cdots	p_{ij}	\cdots
\vdots	\vdots	\vdots		\vdots	\ddots

边缘分布列

根据二维随机变量 (X, Y) 的联合分布列 p_{ij}

随机变量 X 的边缘分布列

$$P(X = x_i) = \sum_{j=1}^{+\infty} P(X = x_i, Y = y_j) = \sum_{j=1}^{+\infty} p_{ij} = p_{i.}$$

随机变量 Y 的边缘分布列

$$P(Y = y_i) = \sum_{i=1}^{+\infty} P(X = x_i, Y = y_j) = \sum_{i=1}^{+\infty} p_{ij} = p_{.j}$$

边缘分布列

二维随机变量联合和边缘分布表示在同一个表格

$X \backslash Y$	y_1	y_2	\cdots	y_j	\cdots	$p_{i\cdot}$
x_1	p_{11}	p_{12}	\cdots	p_{1j}	\cdots	$p_{1\cdot}$
x_2	p_{21}	p_{22}	\cdots	p_{2j}	\cdots	$p_{2\cdot}$
\vdots	\vdots	\vdots		\vdots		\vdots
x_i	p_{i1}	p_{i2}	\cdots	p_{ij}	\cdots	$p_{i\cdot}$
\vdots	\vdots	\vdots		\vdots	\ddots	\vdots
$p_{\cdot j}$	$p_{\cdot 1}$	$p_{\cdot 2}$	\cdots	$p_{\cdot j}$	\cdots	1

例题

有三个数1,2,3, 随机变量 X 表示从这三个数中随机地抽取一个数, 随机变量 Y 表示从1到 X 中随机抽取一个数. 求 (X, Y) 的联合分布列和边缘分布列

离散随机变量的独立性

对离散型随机变量 (X, Y) , 若对所有 (x_i, y_j) 有

$$P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$$

即 $p_{ij} = p_{i\cdot} p_{\cdot j}$, 称**离散随机变量X与Y相互独立**

定理：对离散型随机变量 (X, Y) , 以下两种定义等价

$$p_{ij} = p_{i\cdot} p_{\cdot j} \leftrightarrow F(x_i, y_j) = F_X(x_i) F_Y(y_j)$$

离散随机变量的独立性

定理： 设离散随机变量 X 和 Y 独立, 则对任意集合 $A \in \mathcal{R}, B \in \mathcal{R}$, 有事件 $X \in A$ 和 $Y \in B$ 独立

例题： 设离散型随机变量 X, Y 独立, 求解 (X, Y) 的联合分布列

$X \backslash Y$	Y			$p_{i\cdot}$
	y_1	y_2	y_3	
x_1	$1/8$			
x_2	$1/8$			
$p_{\cdot j}$	$1/6$			

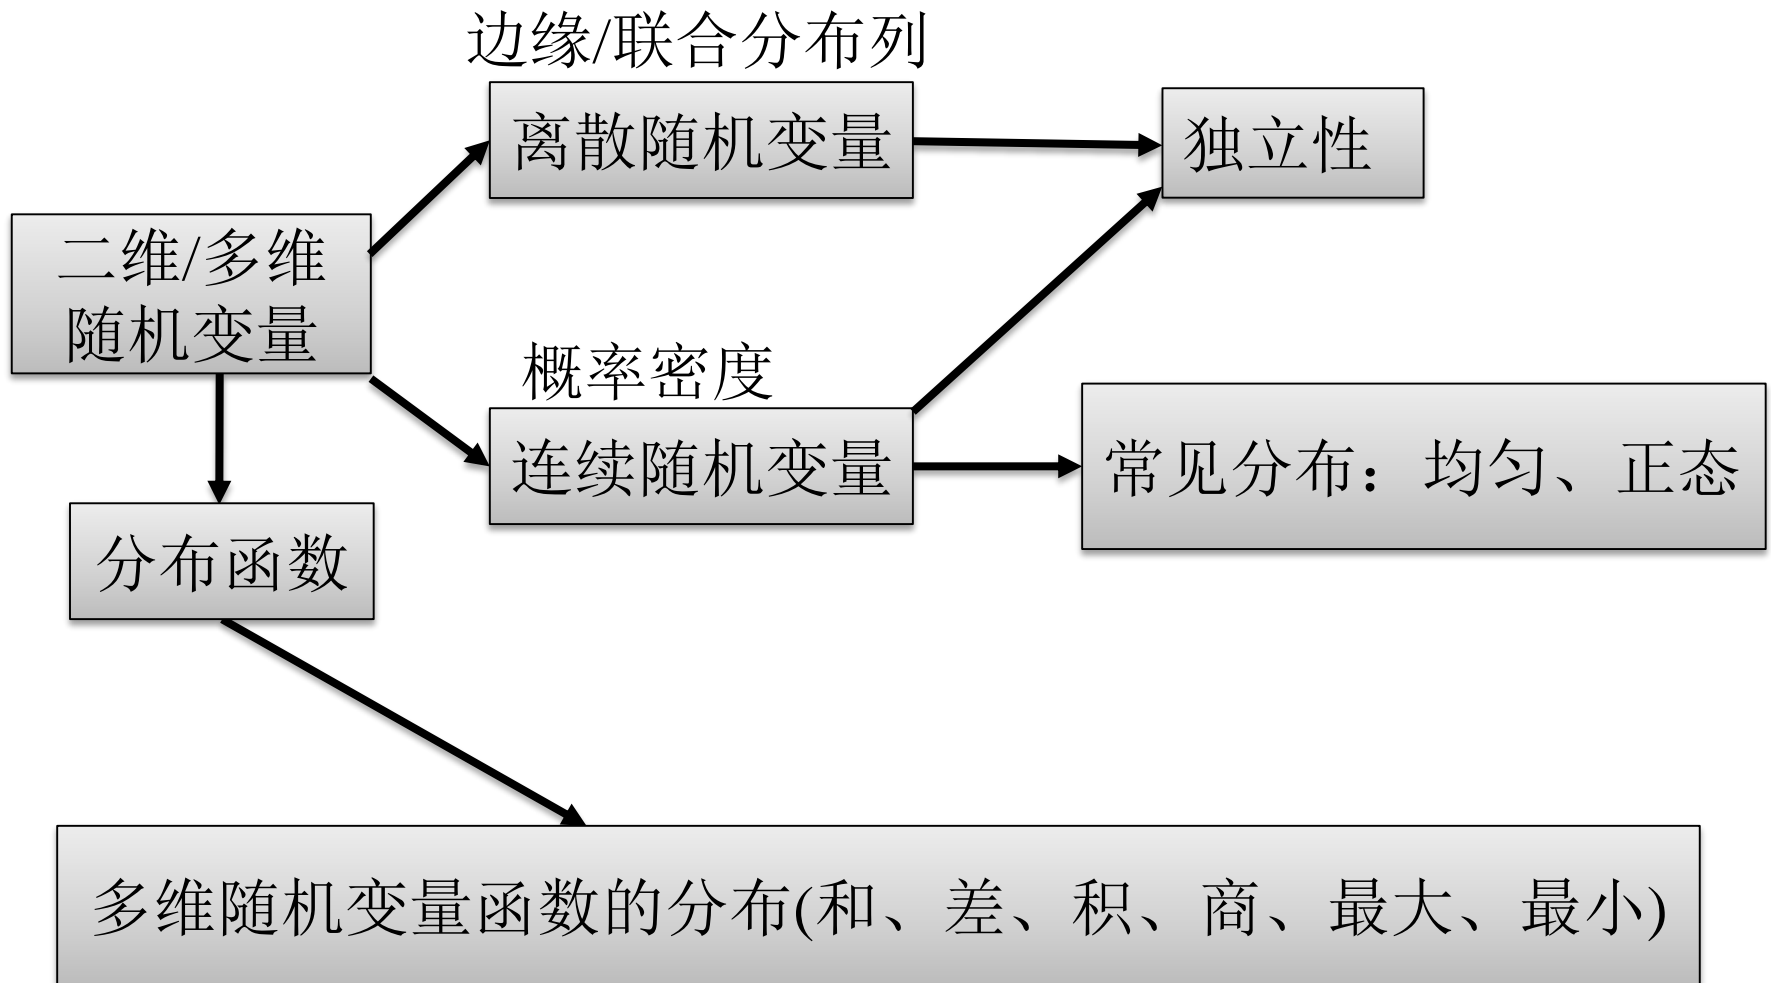
例题

将两个球 A, B 放入编号为1,2,3的三个盒子中, 用随机变量 X 放入1号盒的球数, 用随机变量 Y 表示放入2号盒的球数, 判断 X 和 Y 是否独立

第三章 多维随机变量



知识结构



二维连续型随机变量

二维随机变量的分布函数为 $F(x, y)$, 如存在二元非负可积函数 $f(x, y)$ 使得对 (x, y) 有 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$ 则称 $f(x, y)$ 称为随机变量 (X, Y) 的概率密度, 或称联合概率密度

- 非负性: $f(x, y) \geq 0$;
- 规范性: $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u, v) du dv$
- 若 $f(x, y)$ 在 (x, y) 连续, 则 $f(x, y) = \partial^2 F(x, y) / \partial x \partial y$
- 若 G 为平面上的一个区域, 则点 (X, Y) 落入 G 的概率为

$$P((X, Y) \in G) = \iint_{(x, y) \in G} f(x, y) dx dy$$

例题

设X和Y的分布函数为

$$F(x, y) = \begin{cases} (a - e^{-x})(b - e^{-2y}) & x, y \in [0, +\infty) \\ 0 & \text{其他} \end{cases}$$

其中 a, b 非负, 求 $F(1, 1)$

例题

设 X 和 Y 的概率密度函数为

$$f(x, y) = \begin{cases} A(x + y) & x, y \in [0, 1] \\ 0 & \text{其他} \end{cases}$$

求

- $P(X + Y \leq 1)$
- $P(\max(X, Y) \leq 1/2)$
- $P(\min(X, Y) \leq 1/2)$
- $E[\max(X, Y) + \min(X, Y)]$
- $E[\max(X, Y) \times \min(X, Y)]$

边缘概率密度

设二维随机变量 (X, Y) 的概率密度为 $f(x, y)$, 则随机变量 X 和 Y 的边缘概率密度为

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy \quad f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx$$

随机变量 X 和 Y 相互独立的等价条件:

- 分布函数 $F(x, y) = F_X(x)F_Y(y)$
- 概率密度 $f(x, y) = f_X(x)f_Y(y)$
- 条件概率 $f_{Y|X}(y|x) = f_Y(y)$

例题

设二维随机变量 (X, Y) 的概率密度

$$f(x, y) = \begin{cases} c & 0 < x < 1, x^2 < y < x \\ 0 & \text{其它} \end{cases}$$

求边缘概率密度

练习

1) 设X和Y的分布函数为

$$F(x, y) = \begin{cases} 0 & x \leq 0, y \leq 0 \\ 2xy - x^2 & 0 < x < y < 1 \\ y^2 & 0 < y \leq x, y \leq 1 \\ 2x - x^2 & 0 < x \leq 1, y \geq 1 \\ 1 & 1 < y, 1 < x \end{cases}$$

求X和Y的边缘分布函数

2) 设 (X, Y) 的分布函数为 $F(x, y)$, 边缘分布函数分别为 $F_X(x)$ 和 $F_Y(y)$, 则 $Z = \max(X, Y)$ 的分布函数为()

A) $F_X(x)F_Y(y)$ B) $F_X(x)F_Y(x)$ C) $F(x, x)$ D) $F(x, y)$

二维正态分布

设 $|\rho| < 1$, 令 $\mu = \begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}$ $\Sigma = \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix}$

若随机变量 X 和 Y 的联合概率密度函数为

$$f(x, y) = (2\pi)^{-2/2} |\Sigma|^{-1/2} e^{-\frac{1}{2} (\xi - \mu)^T \Sigma^{-1} (\xi - \mu)} \quad \xi = \begin{pmatrix} x \\ y \end{pmatrix}$$

$$f(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_x)^2}{\sigma_x^2} - 2\rho \frac{(x-\mu_x)(y-\mu_y)}{\sigma_x\sigma_y} + \frac{(y-\mu_y)^2}{\sigma_y^2} \right]}$$

称 X 和 Y 服从参数为 μ 和 Σ 的正太分布, 记 $(X, Y) \sim N(\mu, \Sigma)$

- 参数的含义: μ, Σ, ρ
- X 和 Y 的条件概率
- X 与 Y 的独立性
- 联合分布可以推出边缘分布, 反只不成立

条件概率

条件分布列：二维离散型随机变量 (X, Y) 的分布列为 $\{p_{ij}\}$ ，称

$$P(X = x_i | Y = y_j) = \frac{P(X=x_i, Y=y_j)}{P(Y=y_j)} = \frac{p_{ij}}{p_{\cdot j}} \text{ 在 } Y = y_j \text{ 条件下随机变量}$$

X 的条件分布列

条件概率密度：随机变量 (X, Y) 的联合概率密度为 $f(x, y)$ ，以及 Y 的边缘概率密度为 $f_Y(y) > 0$ ，称 $f_{X|Y}(x|y) = f(x, y)/f_Y(y)$ 在 $Y = y$ 条件下随机变量 X 的条件概率密度

性质与例题

性质：非负性、规范性

条件概率的计算

$$P(a < X < b | Y = y_0) = \int_a^b f_{X|Y}(x|y_0) dx = \int_a^b f(x, y) / f_Y(y_0) dx$$

例题：已知随机变量 $X \sim U(0,1)$ ，当观察到 $X = x$ 的条件下随机变量 $Y \sim U(x, 1)$ ，求 Y 的概率密度以及概率 $P(X + Y \leq 1)$

随机变量函数的分布

离散: $p_{ij} = P(X = x_i, Y = y_j)$, $Z = g(X, Y)$ 将相同值合并

连续: i) 给出分布函数 $f(x, y)$, 求和、差、积

ii) 两个独立随机变量的和、差、积

方法: 公式讨论独立随机变量的和、差、积、商、最大、最小
分布函数法

- Step 1: (X, Y) 的联合概率密度 $f(x, y)$, 则 Z 的分布函数为

$$F_Z(z) = P(g(X, Y) \leq z) = \int_{g(x, y) \leq z} f(x, y) dx dy$$

- Step 2: 求概率密度 $f_Z(z) = F'_Z(z)$

难点: 分类讨论

随机变量函数的结论

多维随机变量函数 $\max(X, Y)$ 和 $\min(X, Y)$

$$f_{X+Y}(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx$$

$$f_{XY}(z) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f\left(x, \frac{z}{x}\right) dx$$

$$f_{Y/X}(z) = \int_{-\infty}^{+\infty} |x| f(x, xz) dx$$

$X \sim B(n_1, p)$ 和 $Y \sim B(n_2, p)$ 独立, $X + Y \sim B(n_1 + n_2, p)$

$X \sim P(\lambda_1)$ 和 $Y \sim P(\lambda_2)$ 独立, 则 $X + Y \sim P(\lambda_1 + \lambda_2)$

$X \sim N(\mu_1, \sigma_1^2)$ 和 $Y \sim N(\mu_2, \sigma_2^2)$ 独立, 则

$$X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$$

例题

设 (X, Y) 的联合概率密度为

$$f(x, y) = \begin{cases} 1 & x, y \in [0, 1] \\ 0 & \text{其他} \end{cases}$$

求 $Z = |X - Y|$ 的概率密度

综合题

设随机变量 (X, Y) 的概率密度为

$$f(x, y) = \begin{cases} Ae^{-y} & y > x > 0 \\ 0 & \text{其它} \end{cases}$$

求1) 常数 A

2) 求 X 与 Y 的边缘概率密度

3) 求 X 与 Y 是否独立?


4) 求 $Z = X + Y$ 的概率密度

5) 求条件概率密度 $f_{X|Y}(x|y)$, 或条件概率 $P(1 < X < 2|Y = 1)$

第四章 随机变量的数字特征



知识结构



期望及其性质

离散随机变量期望 $E(X) = \sum_k p_k x_k$

连续随机变量 $E(X) = \int_{-\infty}^{+\infty} x f(x) dx$

若随机变量 $X \equiv c$, 则 $E(c) = c$

对随机变量 X 和常数 $a, b \in \mathbb{R}$, 有 $E(aX + b) = aE(X) + b$

对随机变量 X, Y 和常数 $a, b \in \mathbb{R}$, 有 $E(aX + bY) = aE(X) + bE(Y)$

对随机变量 X 和连续凸函数 $g: [a, b] \rightarrow \mathbb{R}$, 有 $g(E(X)) \leq E(g(X))$

离散变量 X , 及连续函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 有 $E[g(X)] = \sum_{k \geq 1} g(x_k) p_k$

连续变量 X , 及连续函数 $g: \mathbb{R} \rightarrow \mathbb{R}$, 有 $E(g(X)) = \int_{-\infty}^{+\infty} g(t) f(t) dt$

例题

- 设随机变量 $X \sim E(\lambda)$, 则 $P(X > \sqrt{\text{Var}(X)}) =$
- X 与 Y 相互独立且期望存在, 记 $U = \max(X, Y)$, $V = \min(X, Y)$, 则 $E(UV) =$
- 设 X 与 Y 服从正态分布, 则下列服从正太分布的有()
A) $X + Y$ B) $X - Y$ C) (X, Y) D) $2X + 1$
- 设随机变量 X 的分布函数 $F(x) = 0.3\Phi(x) + 0.7\Phi((x - 1)/2)$, 其中 $\Phi(x)$ 为标准正态分布的分布函数, 则 $E(X) =$
A) 0 B) 0.3 C) 0.7 D) 1

方差的定义及其性质

随机变量方差: $Var(X) = E(X - E(X))^2 = E(X)^2 - (E(X))^2$

- 若随机变量 $X \equiv c$, 则 $Var(X) = 0$
- 对随机变量 X 和常数 $a, b \in R$, 有

$$Var(aX + b) = a^2 Var(X)$$

- 一般情况下方差不具有线性性, 即

$$Var(f(X) + g(X)) \neq Var(f(X)) + Var(g(X))$$

常见分布的期望和方差

- 0/1分布: $X \sim \text{Ber}(p)$, $E(X) = p$ $\text{Var}(X) = p(1 - p)$
 - 二项分布: $X \sim B(n, p)$, $E(X) = np$ $\text{Var}(X) = np(1 - p)$
 - 几何分布: $X \sim G(p)$, $E(X) = \frac{1}{p}$ $\text{Var}(X) = \frac{1-p}{p^2}$
 - 负二项分布: X 服从参数为 r 和 p 的负二项分布
$$E(X) = \frac{r}{p} \quad \text{和} \quad \text{Var}(X) = \frac{r(1-p)}{p^2}$$
 - 泊松分布: $X \sim P(\lambda)$, $E(X) = \lambda$ $\text{Var}(X) = \lambda$
- 均匀分布 $X \sim U(a, b)$: $E(X) = \frac{a+b}{2}$ $\text{Var}(X) = \frac{(b-a)^2}{12}$
- 指数分布 $X \sim e(\lambda)$: $E(X) = \frac{1}{\lambda}$ $\text{Var}(X) = \frac{1}{\lambda^2}$
- 正态分布 $X \sim N(\mu, \sigma^2)$: $E(X) = \mu$ $\text{Var}(X) = \sigma^2$

多元随机变量的期望

离散随机变量 $E[Z] = E[g(X, Y)] = \sum_{i,j} g(x_i, y_j) p_{ij}$

连续随机变量 $E[Z] = E[g(X, Y)] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) f(x, y) dx dy$

- 对任意随机变量 X, Y 和常数 a, b 有 $E[aX + bY] = aE[X] + bE[Y]$
- 对**独立**随机变量 X 和 Y , 以及任意函数 $h(x)$ 和 $g(y)$, 有

$$E[XY] = E[X]E[Y] \text{ 和 } E[h(X)g(Y)] = E[h(X)]E[g(Y)]$$

- 对任意随机变量 X 和 Y , 有Cauchy-Schwartz不等式

$$E[XY] \leq \sqrt{E[X^2]E[Y^2]}$$

协方差及其性质

协方差: $\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$

对随机变量 X 和常数 c , 有 $\text{Cov}(X, c) = 0$.

交换律 $\text{Cov}(X, Y) = \text{Cov}(Y, X)$

对任意常数 a 和 b , 随机变量 X 和 Y , 有

$$\text{Cov}(aX, bY) = ab\text{Cov}(X, Y),$$

$$\text{Cov}(X + a, Y + b) = \text{Cov}(X, Y)$$

$$\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$$

$$\text{Cov}\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m \text{Cov}(X_i, Y_j)$$

$$\text{Var}\left(\sum_i X_i\right) = \sum_i \text{Var}(X_i) + 2 \sum_{i < j} \text{Cov}(X_i, X_j)$$

相关系数的定义

X 与 Y 的相关系数: $\rho_{XY} = \frac{\text{Cov}(X,Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$

- $|\rho_{XY}| = 1$ 的充要条件为 X 与 Y 有线性关系 $Y = aX + b$
- 本质上 ρ_{XY} 刻画了 X 与 Y 的线性相关程度, 又称为“线性相关系数”

若相关系数 $|\rho_{XY}| = 0$, 则随机变量 **X 和 Y 不相关**

X 和 Y 不相关

X 和 Y 独立

例题

随机变量 X 和 Y 在以点 $(0,1)$, $(1,0)$, $(1,1)$ 为顶点的三角形区域服从均匀分布, 求 $U = X - Y$ 的方差

第五章 大数定律与中心极限定理



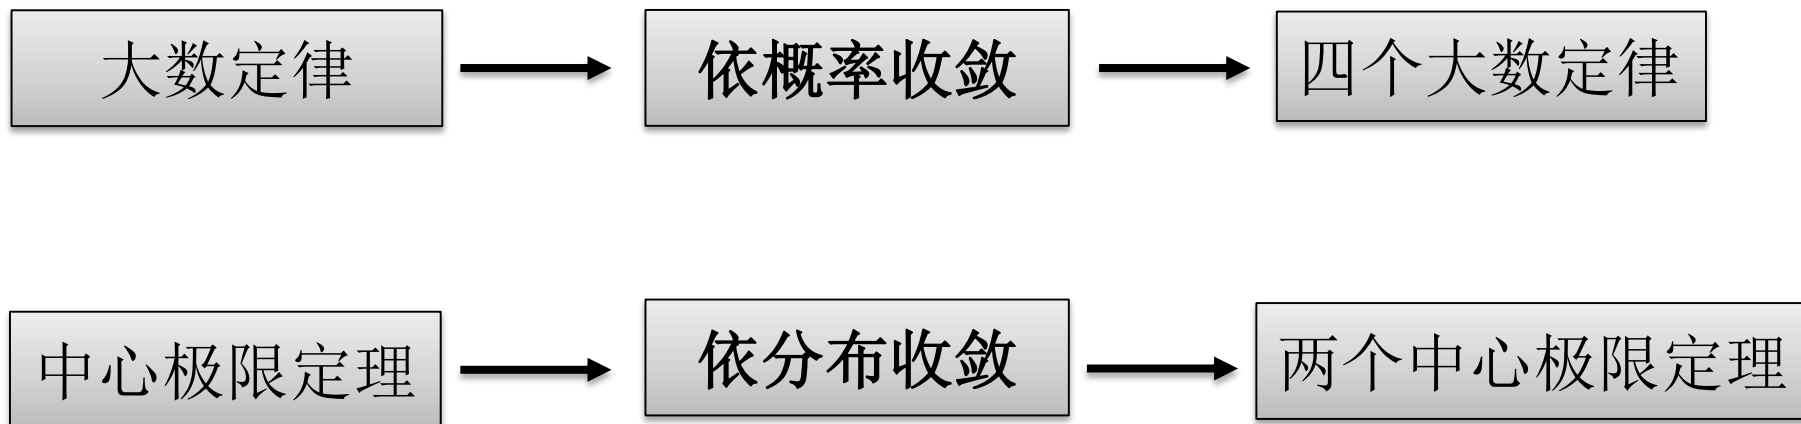
问题

什么是大数定律？

什么是中心极限定理？

其局限是什么，可以采用什么方式弥补

知识结构



大数定律

设 $X_1, X_2, \dots, X_n, \dots$ 是一随机变量序列, a 是一常数, 如果对任意 $\epsilon > 0$ 有 $\lim_{n \rightarrow \infty} P[|X_n - a| < \epsilon] = 1$, or $\lim_{n \rightarrow \infty} P[|X_n - a| > \epsilon] = 0$

则称随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 依概率收敛于 a , 记 $X_n \xrightarrow{P} a$

若随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 满足

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n E[X_i],$$

则称 $\{X_n\}$ 服从大数定律

大数定理刻画了随机变量的均值 (算术平均值) 依概率收敛于期望的均值 (算术平均值)

大数定律总结

Markov大数定律: 若随机变量序列 $\{X_i\}$ 满足 $\text{Var}(\sum_{i=1}^n X_n)/n^2 \rightarrow 0$, 则满足大数定律

Chebyshev大数定律: 若独立随机变量序列 $\{X_i\}$ 满足 $\text{Var}(X_i) \leq c$, 则满足大数定律

Khintchine大数定律: 若独立同分布随机变量序列 $\{X_i\}$ 期望存在, 则满足大数定律

Bernoulli大数定律: 对二项分布 $X_n \sim B(n, p)$, 有 $X_n/n \xrightarrow{P} p$

依分布收敛

设随机变量 Y 的分布函数为 $F_Y(y) = P(Y \leq y)$, 以及随机变量序列 $Y_1, Y_2, \dots, Y_n, \dots$ 的分布函数分别为 $F_{Y_n}(y) = P(Y_n \leq y)$, 如果

$$\lim_{n \rightarrow \infty} P[Y_n \leq y] = P[Y \leq y] \text{ 即 } \lim_{n \rightarrow \infty} F_{Y_n}(y) = F_Y(y)$$

则称随机变量序列 $Y_1, Y_2, \dots, Y_n, \dots$ 依分布收敛于 Y , 记 $Y_n \xrightarrow{d} Y$.

➤ 林德贝格-勒维中心极限定理: 独立同分布随机变量, 若 $E[X_k] = \mu$ 和 $\text{Var}(X_k) = \sigma^2$, 则

$$\frac{\sum_{k=1}^n X_k - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} N(0,1)$$

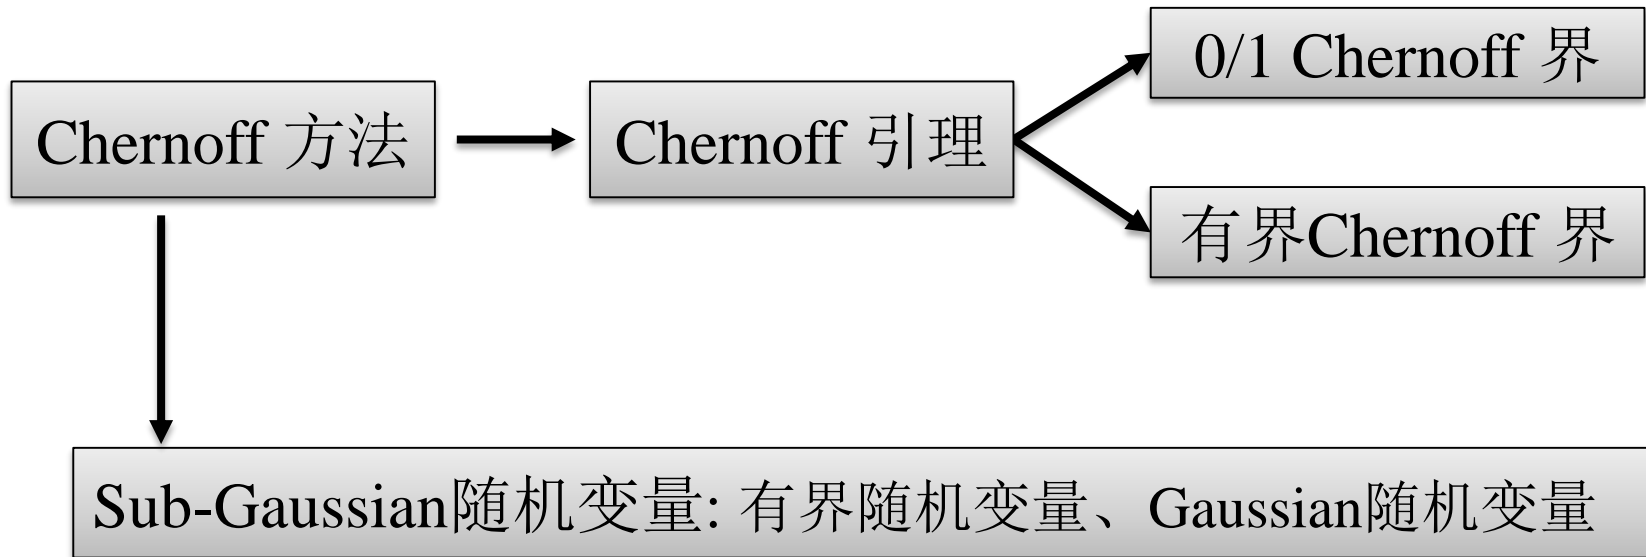
➤ 李雅普诺夫定理: 独立不同分布中心极限定理

第六章 集中不等式



知识结构

基础不等式： Markov不等式、Chebyshev不等式、Hölder不等式、Cauchy-Schwartz不等式、单边Chebyshev不等式



基础不等式

Markov不等式: $P(X \geq \epsilon) \leq \frac{E(X)}{\epsilon}$

Chebyshev不等式: $P(|X - \mu| > \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2}$

单边Chebyshev不等式: $P(X - \mu \geq \epsilon) \leq \frac{\sigma^2}{\sigma^2 + \epsilon^2}$

Hölder不等式: $E(|XY|) \leq (E(|X|^p))^{\frac{1}{p}} (E(|Y|^q))^{\frac{1}{q}}$

例题

随机变量 X 和 Y 满足 $E(X) = 2$, $E(Y) = 2$, $\text{Var}(X) = 1$, $\text{Var}(Y) = 4$, $\rho_{XY} = -1/2$. 利用Chebyshev不等式估计 $P(|X - Y| \geq 6) \leq ???$

设随机变量 $X \sim N(-1, 2)$ 和 $Y \sim E(1)$, 且 X 和 Y 的相关系数为 $-1/2$, 利用Chebyshev不等式估计 $P(|X + Y| \geq 6) \leq ???$

Chernoff方法

对任意 $\epsilon > 0$ 和 $t < 0$ 有

$$P[X \leq -\epsilon] = P[tX \geq -t\epsilon] \leq e^{t\epsilon} E[e^{tX}]$$

同理有

$$P[X \leq -\epsilon] \leq \min_{t < 0} \{e^{t\epsilon} E[e^{tX}]\}.$$

称为Chernoff方法, 是证明集中不等式最重要的方法之一

有界的Chernoff不等式

Chernoff 引理: 随机变量 $X \in [0,1]$ 的期望 $\mu = E[X]$. 对 $\forall t > 0$ 有

$$E[e^{tX}] \leq e^{t\mu + \frac{t^2}{8}}$$

推论: $X \in [a, b]$ 期望 $\mu = E[X]$, 对 $\forall t > 0$ 有 $E[e^{tX}] \leq e^{t\mu + \frac{t^2(b-a)^2}{8}}$

Chernoff不等式: 假设 X_1, \dots, X_n 是 n 独立的随机变量、且满足 $X_i \in [a, b]$. 对任意 $\epsilon > 0$ 有

$$P\left[\frac{1}{n}\sum_{i=1}^n X_i - \frac{1}{n}\sum_{i=1}^n E[X_i] \geq \epsilon\right] \leq e^{-2n\epsilon^2/(b-a)^2}$$
$$P\left[\frac{1}{n}\sum_{i=1}^n X_i - \frac{1}{n}\sum_{i=1}^n E[X_i] \leq -\epsilon\right] \leq e^{-2n\epsilon^2/(b-a)^2}$$


例题

分类器 f 在集合 $S_n = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)\}$ 的错误率为 $\hat{p} > 0$, 请估计分类器 f 在分布 \mathcal{D} 上的错误率, 求 f 在分布 \mathcal{D} 上的错误率为 $(9\hat{p}/10, 11\hat{p}/10)$ 之间的概率.

第七章 统计的基本概念



知识结构

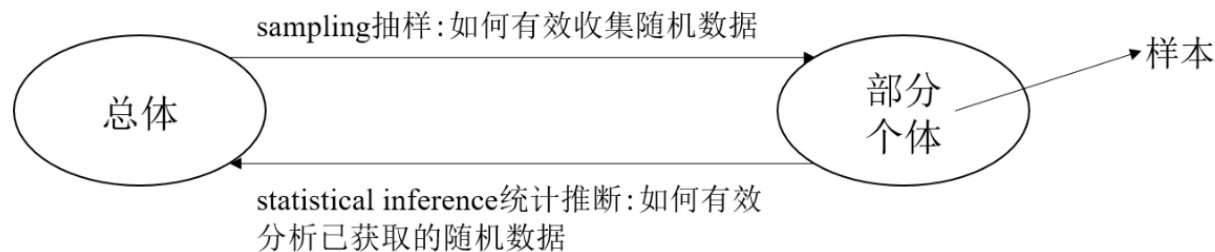


统计学

统计学：以概率论为基础，研究如何有效收集研究对象的随机数据，以及如何运用所获得的数据揭示统计规律的一门学科。

统计学的研究内容包括：

- 抽样
- 参数估计
- 假设检验



统计学基本概念

总体与样本

统计量： $g(X_1, \dots, X_n)$ 关于 X_1, \dots, X_n 连续、且不含任意参数

常见统计量：

- 样本均值
- 样本方差
- 样本标准差
- 修正后的样本方差
- k 阶原点矩/中心矩
- 次序统计量


欧拉积分函数及其分布(了解)

- Beta函数: $\text{Beta}(\alpha_1, \alpha_2) = \int_0^1 x^{\alpha_1-1} (1-x)^{\alpha_2-1} dx$
- Γ -函数为 $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$
- 两类函数的关系
- Beta分布
- Γ -分布、性质、独立可加性
- 标准正态分布的平方 $\Gamma(1/2, 1/2)$
- Dirichlet分布、性质

χ^2 分布

若 X_1, X_2, \dots, X_n 是来自总体 $X \sim N(0,1)$ 的一个样本, 称 $Y = X_1^2 + X_2^2 + \dots + X_n^2$ 为服从自由度为 n 的 χ^2 分布, 记 $Y \sim \chi^2(n)$

根据 $X_1^2 \sim \Gamma(1/2, 1/2)$ 和 Γ 分布的独立可加性可得 $Y \sim \Gamma(n/2, 1/2)$



定理: 随机变量 $X \sim \chi^2(n)$, 则 $E(X) = n$ 和 $\text{Var}(X) = 2n$;


若随机变量 $X \sim \chi^2(m)$ 和 $Y \sim \chi^2(n)$ 相互独立, 则 $X + Y \sim \chi^2(m + n)$

t分布(student distribution)

随机变量 $X \sim N(0,1)$ 和 $Y \sim \chi^2(n)$ 相互独立, 则随机变量

$$T = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t -分布, 记 $T \sim t(n)$.



定理: 当 $n \rightarrow \infty$ 时, 随机变量 $T \sim t(n)$ 的概率密度

$$f(x) \rightarrow \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$


因此当 n 足够大时, $f(x)$ 被近似为 $N(0,1)$ 的密度函数.

F分布

随机变量 $X \sim \chi^2(m)$ 和 $Y \sim \chi^2(n)$ 相互独立, 称随机变量

$$F = \frac{X/m}{Y/n}$$

服从自由度为 (m, n) 的 F -分布, 记 $F \sim F(m, n)$.



定理: 若随机变量 $F \sim F(m, n)$, 则 $1/F \sim F(n, m)$.

例题

- 设 X_1, X_2, X_3, X_4 是来自于总体 $N(0,4)$ 的样本, 以及 $Y = a(X_1 - 2X_2)^2 + b(3X_3 - 4X_4)^2$. 求 a, b 取何值时, Y 服从 χ^2 分布, 并求其自由度.
- 独立同分布随机变量 X_1, X_2, \dots, X_n 满足 $X_i \sim N(\mu_i, \sigma_i^2)$, 求 $\sum_{i=1}^n (X_i - \mu_i)^2 / \sigma_i^2$ 的分布
- X_1, X_2, \dots, X_9 和 Y_1, Y_2, \dots, Y_9 是来自总体 $N(0,9)$ 两样本, 求 $(X_1 + X_2 + \dots + X_9) / \sqrt{Y_1^2 + Y_1^2 + \dots + Y_9^2}$ 的分布
- 设 X_1, X_2, \dots, X_{2n} 来自总体 $N(0, \sigma_2^2)$ 的样本, 求 $(X_1^2 + X_3^2 + \dots + X_{2n-1}^2) / (X_2^2 + X_4^2 + \dots + X_{2n}^2)$ 的分布

例题

- 若随机变量 $X \sim t(n)$, 求 $Y = X^2$ 的分布.
- 设 X_1, X_2, \dots, X_5 是来自总体 $N(0,1)$ 的样本, 令 $Y = c_1(X_1 +$

抽样分布定理

定理一：设 X_1, X_2, \dots, X_n 是来自总体 $N(\mu, \sigma^2)$ 的样本, 则有

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N(\mu, \sigma^2/n) \qquad \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1).$$

定理二：设 X_1, X_2, \dots, X_n 是来自总体 $N(\mu, \sigma^2)$ 的样本, 其样本均值和修正样本方差分别为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \qquad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

则有 \bar{X} 和 S^2 相互独立, 且

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

抽样分布定理

定理三： 设 X_1, X_2, \dots, X_m 是来自总体 $N(\mu, \sigma^2)$ 的样本,其样本均值和修正样本方差分别为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

则

$$\frac{\bar{X} - \mu}{\sqrt{S^2/n}} \sim t(n-1)$$

定理四： 设 X_1, X_2, \dots, X_m 和 Y_1, Y_2, \dots, Y_n 分别来自总体 $N(\mu_X, \sigma_X^2)$ 和 $N(\mu_Y, \sigma_Y^2)$ 的两个独立样本, 其修正样本方差分别为 S_X^2 和 S_Y^2 , 则

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F(m-1, n-1).$$

正态分布的抽样分布定理五

定理五： 设 X_1, X_2, \dots, X_m 和 Y_1, Y_2, \dots, Y_n 分别来自总体 $N(\mu_X, \sigma^2)$ 和 $N(\mu_Y, \sigma^2)$ 的两个独立样本，令其样本均值分别 \bar{X} 和 \bar{Y} ，修正样本方差分别为 S_X^2 和 S_Y^2 ，则

$$\frac{\bar{X} - \bar{Y} - (\mu_X - \mu_Y)}{\sqrt{\frac{(m-1)S_X^2 + (n-1)S_Y^2}{m+n-2}} \sqrt{\frac{1}{m} + \frac{1}{n}}} \sim t(m+n-2).$$


分位数

对正态分布 $X \sim N(0,1)$, 给定 $\alpha \in (0,1)$, 满足

$$P(X > \mu_\alpha) = \int_{\mu_\alpha}^{\infty} f(x)dx = \alpha$$

的点 μ_α 称为正态分布上侧 α 分位点


$$\alpha = 1 - \Phi(\mu_\alpha), \quad \mu_{1-\alpha} = -\mu_\alpha$$



对 χ^2 分布 $X \sim \chi^2(n)$, 给定 $\alpha \in (0,1)$, 满足

$$P(X \geq \chi_\alpha^2(n)) = \alpha$$

的点 $\chi_\alpha^2(n)$ 称为 $\chi^2(n)$ 分布上侧 α 分位点



t -分布和 F -分布的分位数

对 t -分布 $X \sim t(n)$, 给定 $\alpha \in (0,1)$, 满足 $P(X > t_\alpha(n)) = \alpha$

的点 $t_\alpha(n)$ 称为 $t(n)$ -分布上侧 α 分位点

由对称性可知 $t_{1-\alpha}(n) = -t_\alpha(n)$

对 F -分布 $X \sim F(m, n)$, 给定 $\alpha \in (0,1)$, 满足

$$P[X > F_\alpha(m, n)] = \alpha$$

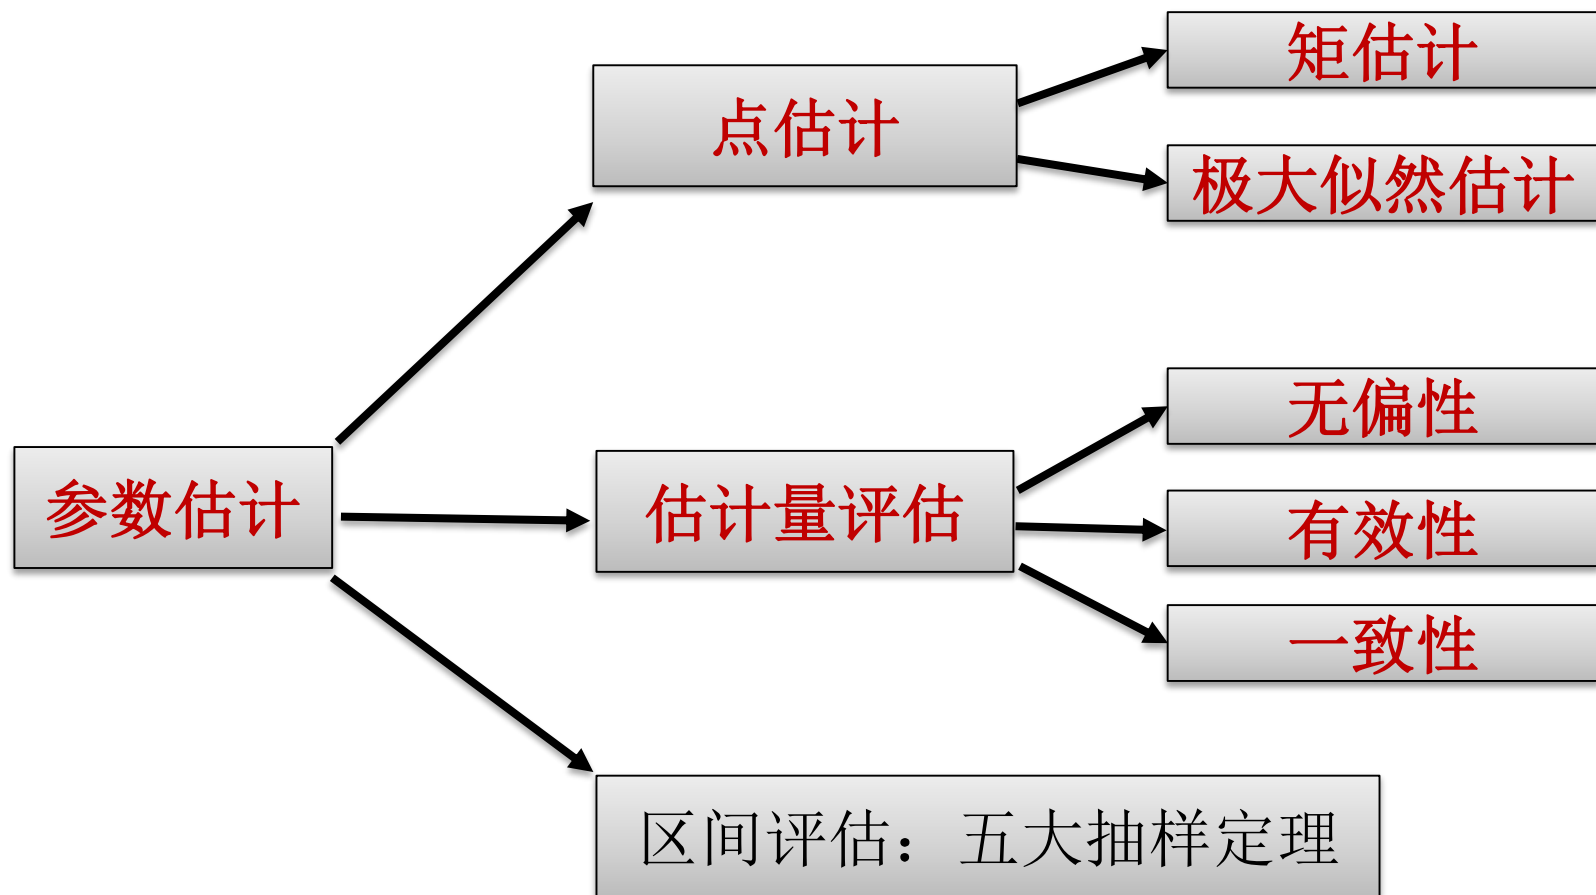
的点 $F_\alpha(m, n)$ 称为 $F(m, n)$ 分布上侧 α 分位点

对 F -分布的分位点有 $F_{1-\alpha}(m, n) = \frac{1}{F_\alpha(n, m)}$.

第八章 参数估计



知识结构



参数估计

设总体 X 的分布/密度函数为 $F(X, \theta)$, 其中 θ 为未知参数

现从总体中抽取一样本 X_1, X_2, \dots, X_n

问题：如何依据样本 X_1, X_2, \dots, X_n 估计参数 θ , 或 θ 的函数 $g(\theta)$, 此类问题称为 **参数估计问题**

- 研究内容包括: 点估计, 估计量标准, 区间估计
- 点估计包括: 矩估计法、极大似然估计法

矩估计法

总体 X 的 k 阶矩: $a_k = E[X^k]$ 样本 k 阶矩: $A_k = \sum_{i=1}^n X_i^k$

用**样本矩去估计总体矩**求参数 θ 的方法称为 矩估计法

总体 X 的 k 阶中心矩: $b_k = E[(X - E(X))^k]$

样本 k 阶中心矩: $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

用**样本中心矩去估计总体中心矩**求参数 θ 的方法亦称为 矩估计法

基础: 独立同分布变量 X_1, \dots, X_n , 若 $E(X) = \mu$, 则 $\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu$

矩估计方法

总体 X 的分布函数 F 包含 m 个未知参数 $\theta_1, \theta_2, \dots, \theta_m$

- 计算总体 X 的 k 阶矩: $a_k = a_k(\theta_1, \theta_2, \dots, \theta_m) = E[X^k]$ $k \in [m]$
(a_k 一般为 $\theta_1, \theta_2, \dots, \theta_m$ 的函数)
- 计算样本的 k 阶矩: $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
- 令样本矩等于总体矩:

$$A_k = a_k = a_k(\theta_1, \theta_2, \dots, \theta_m) \quad k \in [m]$$

得到 m 个关于 $\theta_1, \theta_2, \dots, \theta_m$ 的方程组

- 求解方程组得到估计量 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$

最大似然估计（离散）

设 X_1, X_2, \dots, X_n 是来自总体 X 的一个样本.

若总体 X 为离散型随机变量, 其分布列为 $P(X = x) = P(X = x; \theta)$, 则样本 X_1, X_2, \dots, X_n 的分布列为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n P(x_i; \theta)$$

这里 $L(\theta)$ 表示样本 $X_1 = x_1, \dots, X_n = x_n$ 发生的概率

称 $L(\theta)$ 为样本 X_1, X_2, \dots, X_n 的似然函数

最大似然估计（连续）

若总体 X 为连续型随机变量，其概率密度为 $f(x; \theta)$ ，则 $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ 的联合概率密度为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$$

根据概率密度定义可知 $L(\theta)$ 越大，样本 X_1, X_2, \dots, X_n 落入 x_1, x_2, \dots, x_n 的邻域内概率越大

称 $L(\theta)$ 为样本 X_1, X_2, \dots, X_n 的似然函数

最大似然函数及不变性

综合离散和连续随机变量, 统称 $L(\theta)$ 为样本 X_1, X_2, \dots, X_n 的似然函数, 若

$$\hat{\theta} = \operatorname{argmax}_{\theta} L(x_1, x_2, \dots, x_m; \theta)$$

则称 $\hat{\theta}$ 为 θ 的最大似然估计量

最大似然估计量 $\hat{\theta}$ 是使观测值 $X_1 = x_1, \dots, X_n = x_n$ 出现概率最大

定理: 设 $\mu(\theta)$ 为 θ 的函数且存在反函数 $\theta = \theta(\mu)$. 若 $\hat{\theta}$ 是 θ 的最大似然估计, 则 $\hat{\mu} = \mu(\hat{\theta})$ 是 μ 的最大似然估计,

称为最大似然估计的不变性

求解与例题

求解步骤

- 计算对数似然函数 $\ln(L(x_1, x_2, \dots, x_m; \theta))$
- 求对数似然函数中参数 θ 的一阶偏导, 令其等于零
- 求解方程组得到最大似然估计量 $\hat{\theta}$

设总体 X 的概率密度函数

$$f(x) = \begin{cases} (\alpha + 1)x^\alpha & x \in (0,1) \\ 0 & \text{其它} \end{cases}$$

设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 求 α 的矩估计和极大似然估计

例题

设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 以及总体 X 的密度函数为

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-(x-\mu)/\theta} & x \geq \mu \\ 0 & \text{其它} \end{cases}$$

其中 $\theta > 0$, 求 μ 和 θ 的极大似然估计

设 X_1, \dots, X_n 是取自总体 $X \sim B(1, p)$ 的样本, 求 p 的最大似然估计

估计量的评价标准

不同的估计方法可能得到不同的估计值, 哪一种估计量更好, 或更好的标准是什么呢?

无偏性、有效性、一致性

设 X_1, X_2, \dots, X_n 来自总体 X 的样本, 令 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的一个估计量, 若

$$E_{X_1, X_2, \dots, X_n} [\hat{\theta}] = E_{X_1, X_2, \dots, X_n} [\hat{\theta}(X_1, X_2, \dots, X_n)] = \theta$$

则称 $\hat{\theta}$ 为 θ 的无偏估计

无偏估计要求在期望的情形下有 $E(\hat{\theta}) = \theta$ 成立, 无系统性偏差

无偏估计不具有函数不变性: $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的无偏估计, 但并不一定有 $g(\hat{\theta})$ 是 $g(\theta)$ 的无偏估计

有效性

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 是 θ 的两个无偏估计, 若

$$\text{Var}(\hat{\theta}_1) \leq \text{Var}(\hat{\theta}_2)$$

则称 **θ_1 比 θ_2 有效**

有效统计量(了解)

随机变量 X 的概率密度为 $f(x; \theta)$ 或分布函数为 $F(x; \theta)$, 令

$$\text{Var}_0(\theta) = \left[nE \left(\frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2 \right]^{-1}$$

$$\text{Var}_0(\theta) = \left[nE \left(\frac{\partial \ln F(X; \theta)}{\partial \theta} \right)^2 \right]^{-1}$$

对任意的无偏估计量 $\hat{\theta}$ 有 $\text{Var}(\hat{\theta}) \geq \text{Var}_0(\theta)$, 称 $\text{Var}_0(\theta)$ 为估计量 $\hat{\theta}$ 方差的下界.

当 $\text{Var}(\hat{\theta}) = \text{Var}_0(\theta)$ 时称 $\hat{\theta}$ 为达到方差下界的无偏估计量, 此时 $\hat{\theta}$ 为最有效估计量, 简称**有效估计量**

一致性

设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 是 θ 的一个估计量, 若当 $n \rightarrow \infty$ 时有 $\hat{\theta}_n \xrightarrow{P} \theta$ 成立, 即对任意 $\epsilon > 0$ 有 $\lim_{n \rightarrow \infty} P[|\hat{\theta}_n - \theta| > \epsilon] = 0$, 则称 $\hat{\theta}_n$ 为 θ 的一致估计量

定理: 设 $\hat{\theta}_n = \hat{\theta}_n(X_1, X_2, \dots, X_n)$ 是 θ 的一个估计量, 若满足:

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta \quad \lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 为 θ 的一致估计量.

综合例题

设 X_1, \dots, X_n 是取自总体 X 的一个样本，且总体 X 的密度函数为

$$f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

- 1) 求 θ 的极大似然函数估计 $\hat{\theta}$
- 2) 设 $Z = n \min\{X_1, X_2, \dots, X_n\}$ ，求证 Z 和 $\hat{\theta}$ 均为 θ 的无偏估计量
- 3) 请问 $\hat{\theta}$ 和 Z 哪个估计量更有效
- 4) $\hat{\theta}$ 是否为一贯统计量

第九章 假设检验



知识结构（概念+原理）

假设检验基本思想: 小概率原理(小概率事件在一次实验中不应该发生)

假设检验概念

两类错误

显著性检验

显著性检验基本步骤

假设检验

根据样本信息来检验关于总体的某个假设是否正确, 此类问题称为 **假设检验问题**, 可分为参数检验问题和非参数检验问题

假设检验方法(反证): 先假设所做的假设 H_0 成立, 然后从总体中取样, 根据样本来判断是否有 **不合理** 的现象出现, 最后做出接受或者拒绝所做假设的决定.

不合理的现象: 小概率事件在一次事件中几乎不会发生

假设检验的两类错误

- 第一类错误: 拒绝实际真的假设 H_0 (弃真)
- 第二类错误: 接收实际不真的假设 H_0 (存伪)

小事件

假设检验中需要对 **不合理** 的小事件给出一个定性描述, 通常给出一上界 α , 当一事件发生的概率小于 α 时则成为小概率事件

通常取 $\alpha = 0.05, 0.1, 0.01$, 其具体取值根据实际问题而定. 在假定 H_0 成立下, 根据样本提供的信息判断出不合理的现象 (概率小于 α 的事件发生), 则认为假设 H_0 不显著, α 被称为显著水平.

注意: 不否定假设 H_0 并不是肯定假设 H_0 一定成立, 只能说差异不够显著, 没达到否定的程度, 所以假设检验被称为“**显著性检验**”

假设检验的一般步骤

- 根据实际问题提出原假设 H_0 和备择假设 H_1
- 确定检验统计量 (分布已知)
- 确定显著性水平 α , 并给出拒绝域
- 由样本计算统计量的实测值, 判断是否接受原假设 H_0

问题：正态总体情形下的期望与方差检验 + 五大抽样定理